

Test Report – dev_dito

Projekt	dev_dito – Wiki-Embedding-Pipeline & Service-Gateway
Branch	009-analysis-and-production-polish
Datum	2026-03-19
Python	3.13.7
pytest	8.4.2
Gesamtergebnis	394 bestanden · 0 fehlgeschlagen · 2 übersprungen

1. Testspezifikation

Jeder Testfall beschreibt eine prüfbare Anforderung aus den User Stories oder der Systemarchitektur. Ein Testfall besteht aus nummerierten Schritten mit dem jeweiligen erwarteten Ergebnis.

Infrastruktur

TC-INF-01: Docker Compose – Syntaxvalidität

Bezug: Docker-Infrastruktur · Constitution Art. III

#	Schritt	Erwartetes Ergebnis
1	<code>docker-compose.yml</code> im Repo-Root öffnen und als YAML parsen	Datei existiert, gültiges YAML ohne Parse-Fehler
2	<code>services</code> -Schlüssel und Projektname prüfen	<code>name: "stack-g-devdito"</code> und <code>services</code> -Sektion vorhanden
3	Alle referenzierten Dockerfiles auf Existenz prüfen	Alle Dockerfile-Pfade existieren auf Disk
4	Netzwerkkonfiguration prüfen	<code>leonidas-network</code> definiert und als <code>external: true</code> markiert

TC-INF-02: Keine hartcodierten Secrets

Bezug: Constitution Art. VI (Secret Containment)

#	Schritt	Erwartetes Ergebnis
1	<code>docker-compose.yml</code> nach Secret-Mustern (API-Keys, Passwörter, Tokens) durchsuchen	Keine Treffer
2	Alle Dockerfiles nach denselben Secret-Mustern durchsuchen	Keine Treffer

TC-INF-03: Pflicht-Services vorhanden

Bezug: Docker-Infrastruktur

#	Schritt	Erwartetes Ergebnis
1	Services-Liste aus <code>docker-compose.yml</code> lesen	Services-Dict vorhanden
2	Prüfen ob <code>orchestrator</code> in der Liste enthalten ist	Service vorhanden
3	Prüfen ob <code>qdrant</code> in der Liste enthalten ist	Service vorhanden
4	Jeden Service auf <code>container_name</code> -Feld prüfen	Alle Services haben <code>container_name</code>

Konfiguration

TC-CFG-01: YAML-Konfiguration mit Placeholder-Auflösung

Bezug: Constitution Art. II-B (Centralized YAML Configuration)

#	Schritt	Erwartetes Ergebnis
1	YAML-Datei mit gültigem APP-Abschnitt laden	Dict mit <code>APP.name</code> und <code>APP.version</code> zurückgegeben
2	Config-Dict mit <code>\${root_dir}</code> -Placeholder erstellen	Placeholder vor Auflösung sichtbar
3	<code>resolve_placeholders()</code> aufrufen	<code>\${root_dir}</code> durch tatsächlichen Pfad ersetzt
4	Drei verschachtelte Placeholder auflösen (root → config → secrets)	Alle drei Ebenen korrekt aufgelöst
5	Nicht auflösbaren Placeholder übergeben	Placeholder bleibt unverändert erhalten

TC-CFG-02: Konfigurationshash (NFR-005)

Bezug: NFR-005 – Reproduzierbarkeit von Experimenten

#	Schritt	Erwartetes Ergebnis
1	Config-Dict erstellen und <code>compute_config_hash()</code> aufrufen	SHA-256-Hash zurückgegeben
2	Gleichen Dict erneut hashen	Identischer Hash (deterministisch)
3	<code>_meta</code> -Feld (z. B. Zeitstempel) hinzufügen und erneut hashen	Hash identisch – Meta-Daten ausgeschlossen
4	Config-Wert ändern und erneut hashen	Anderer Hash

Orchestrator

TC-ORC-01: Pipeline-Stufenstruktur (FR-013)

Bezug: FR-013 – Unified Stage Dictionary

#	Schritt	Erwartetes Ergebnis
1	<code>PIPELINE_STAGES</code> -Konstante aus <code>server.py</code> importieren	Dict mit genau 5 Einträgen
2	Keys der Stages prüfen	<code>[fetch, evaluate, preprocess, embed, deploy]</code> in dieser Reihenfolge
3	Jede Stage auf Pflichtfelder prüfen	Alle haben <code>name</code> , <code>container</code> , <code>pipeline_dir</code>
4	<code>embed</code> -Stage auf <code>needs_openai_key</code> prüfen	<code>True</code> ; alle anderen Stages: <code>False</code>

TC-ORC-02: Gleichzeitige Jobs abweisen (FR-004)

Bezug: FR-004 – Concurrent Job Rejection (HTTP 409)

#	Schritt	Erwartetes Ergebnis
1	<code>pipeline_runs.json</code> mit einem laufenden Job (<code>status='running'</code>) simulieren	Testdaten bereit
2	<code>get_active_job()</code> aufrufen	Gibt den laufenden Job zurück
3	Alle Jobs auf <code>status='success'</code> setzen	Keine laufenden Jobs mehr
4	<code>get_active_job()</code> erneut aufrufen	Gibt <code>None</code> zurück

US1 – CLI UX

TC-US1-01: Hilfe-Banner der CLI

Bezug: US1 – CLI UX · `pipeline/shared/cli_utils.py`

#	Schritt	Erwartetes Ergebnis
1	<code>run_preprocessing.py --help</code> ausführen	Programm startet ohne Absturz
2	Exit-Code prüfen	<code>SystemExit(0)</code>
3	Ausgabe auf vollständigen Hilfe-Inhalt prüfen	Abschnitte What / Usage / Parameters / Options / Examples vorhanden
4	<code>print_help_banner()</code> mit nur <code>what</code> -Parameter aufrufen	Nur What-Abschnitt ausgegeben, andere weggelassen

TC-US1-02: SIGINT-Signalbehandlung (Ctrl+C)

Bezug: US1 – CLI UX · `cli_utils.create_sigint_handler`

#	Schritt	Erwartetes Ergebnis
1	SIGINT-Handler mit optionalem Callback registrieren	Handler registriert
2	SIGINT-Signal auslösen	Callback einmal aufgerufen
3	Exit-Code prüfen	<code>SystemExit(130)</code>
4	Stderr auf Abbruch-Banner prüfen	"ABGEBROCHEN" in Ausgabe

US2 – Deep Evaluation Bugfixes

TC-US2-01: Datei-Deduplizierung bei rglob

Bezug: US2 – Bug: Duplikate bei gemischter Groß-/Kleinschreibung

#	Schritt	Erwartetes Ergebnis
1	Verzeichnis mit <code>dokument.pdf</code> und <code>DOKUMENT.PDF</code> anlegen	Verzeichnis bereit
2	<code>analyze_documents()</code> aufrufen	Funktion läuft durch
3	Ergebnisliste auf Duplikate prüfen	Jede Datei nur einmal in der Liste

TC-US2-02: Temperature-Passthrough zum LLM

Bezug: US2 – Bug: Temperature aus `env.yaml` erreicht LLM nicht

#	Schritt	Erwartetes Ergebnis
1	<code>env.yaml</code> laden und <code>LLM.generation.temperature</code> auslesen	Wert = 0.0
2	<code>LLMClient</code> mit dieser Config initialisieren	Client erstellt
3	<code>gen_params</code> des Clients prüfen	<code>temperature = 0.0</code>

US3 – Schema Alignment

TC-US3-01: JSON-Schema-Validierung Pipeline Runs

Bezug: US3 – Constitution Art. II (JSON Interface Standard)

#	Schritt	Erwartetes Ergebnis
1	<code>data/logs/pipeline_runs.schema.json</code> laden	Valides JSON-Schema, <code>type = 'array'</code>
2	Pflichtfelder-Liste prüfen	<code>job_id</code> , <code>stage</code> , <code>status</code> , <code>started_at</code> vorhanden
3	Stage-Enum prüfen	Alle 5 Stages enthalten: <code>fetch</code> , <code>evaluate</code> , <code>preprocess</code> , <code>embed</code> , <code>deploy</code>
4	Sample-Daten gegen Schema validieren	Validierung erfolgreich
5	Daten ohne <code>job_id</code> validieren	<code>ValidationError</code> ausgelöst
6	Ungültigen Stage-Wert <code>"invalid_stage"</code> validieren	<code>ValidationError</code> ausgelöst

TC-US3-02: Frontmatter-Schema E2E-Roundtrip

Bezug: US3 – T005 · Qdrant-Schema-Compliance

#	Schritt	Erwartetes Ergebnis
1	Sample-Seite mit vollständigen Metadaten durch <code>Exporter.export()</code> verarbeiten	Markdown-Datei mit YAML-Frontmatter erstellt
2	Exportierte Datei mit <code>DocumentLoader</code> laden	Datei gelesen ohne Fehler
3	Alle 14 Pflichtfelder im Frontmatter prüfen	Alle vorhanden und korrekt typisiert
4	<code>content_hash</code> gegen MD5 des Body-Textes prüfen	Hash stimmt überein (32 Hex-Zeichen)
5	Media-Datei exportieren und auf <code>media_id</code> -Feld prüfen	<code>media_id</code> vorhanden, kein <code>page_id</code>

US4 – Strategy Integration

TC-US4-01: Strategy Loader – YAML laden

Bezug: US4 – T064/T013 · StrategyLoader

#	Schritt	Erwartetes Ergebnis
1	<code>preprocessing_strategies.yaml</code> in tmp-Verzeichnis erstellen	Datei vorhanden
2	<code>StrategyLoader().load(dir)</code> aufrufen	Strategien geladen ohne Fehler
3	<code>get_strategy("departm:electronics")</code> aufrufen	<code>ContentType.KNOWLEDGE</code> , <code>chunking="recursive_header"</code>
4	<code>get_strategy("start")</code> aufrufen	<code>ContentType.PORTAL</code> , <code>chunking="parent_context"</code>
5	<code>is_ignored("abotest20210218")</code> aufrufen	<code>True</code>
6	<code>get_strategy("nonexistent:page")</code> aufrufen	Default: KNOWLEDGE, semantic, process

TC-US4-02: Content-Type-Routing

Bezug: US4 – T076 · PageProcessor.process_with_strategy

#	Schritt	Erwartetes Ergebnis
1	Seite mit <code>PageStrategy(content_type=KNOWLEDGE)</code> verarbeiten	<code>result["content_type"] = "knowledge"</code>
2	Seite mit <code>NEWS</code> -Typ verarbeiten	<code>result["content_type"] = "news"</code>
3	Seite mit <code>ARCHIVED</code> -Typ verarbeiten	<code>result["priority"] = "low"</code>

US5 – Freshness-Scoring

TC-US5-01: Freshness-Score-Berechnung

Bezug: US5 – T017/T077 · MetadataEnricher

#	Schritt	Erwartetes Ergebnis
1	Datum von vor 26 Tagen übergeben	<code>score=1.0</code> , <code>category="fresh"</code>
2	Datum von vor 300 Tagen übergeben	<code>score=0.85</code> , <code>category="fresh"</code>
3	Datum von vor 650 Tagen übergeben	<code>score=0.70</code> , <code>category="recent"</code>
4	Datum von vor 800 Tagen übergeben	<code>score=0.50</code> , <code>category="outdated"</code>
5	Namespace <code>"archive: ..."</code> mit beliebigem Datum übergeben	<code>score=0.20</code> , <code>category="archived"</code>
6	Ungültiges Datum übergeben	<code>score=0.5</code> , <code>category="unknown"</code>

US6 – Vision-LLM Bildunterschriften

TC-US6-01: Bildunterschriftsgenerierung

Bezug: US6 – T026 · ImageCaptioner

#	Schritt	Erwartetes Ergebnis
1	<code>ImageCaptioner</code> mit gemocktem API-Client initialisieren	Objekt erstellt
2	<code>caption(png_file)</code> mit gültigem Bild und gemockter LLM-Antwort aufrufen	Nicht-leerer Beschreibungsstring
3	<code>caption()</code> mit nicht-existentм Pfad aufrufen	<code>""</code> zurückgegeben, kein Absturz
4	<code>CAPTIONABLE_EXTENSIONS</code> auf <code>.png</code> , <code>.jpg</code> , <code>.jpeg</code> prüfen	Alle enthalten
5	<code>CAPTIONABLE_EXTENSIONS</code> auf <code>.pdf</code> prüfen	Nicht enthalten

US7 – PDF-Qualität

TC-US7-01: PDF-Textbereinigung

Bezug: US7 – T021 · MediaProcessor._fix_spaced_characters / _merge_short_lines

#	Schritt	Erwartetes Ergebnis
1	<code>_fix_spaced_characters("H T B L A L e o n d i n g")</code> aufrufen	<code>"HTBLA Leonding"</code>
2	Normalen Text durch <code>_fix_spaced_characters()</code> laufen lassen	Text unverändert
3	Mehrere kurze Zeilen (<40 Zeichen) durch <code>_merge_short_lines()</code> laufen lassen	Zeilen zusammengeführt
4	Markdown-Überschriften (<code># ...</code>) durch <code>_merge_short_lines()</code> laufen lassen	Überschriften getrennt erhalten
5	<code>clean_pdf_text()</code> mit Spaced-Chars und kurzen Zeilen aufrufen	Beide Operationen angewendet

US8 – Preprocessing-Evaluierung

TC-US8-01: 7-Metrik-Qualitätssuite

Bezug: US8 – T037 · DocumentScore / 7 Metriken

#	Schritt	Erwartetes Ergebnis
1	Gleichen Text als Original und Verarbeitung übergeben	<code>content_completeness = 1.0</code>
2	DokuWiki-Link <code>`[[start</code>	<code>Startseite]]</code> durch <code>LinkIntegrityMetric`</code> prüfen
3	Sauberes Markdown durch <code>NoiseDetectionMetric</code> prüfen	<code>Score ≤ 0.02</code>
4	Wiki-Syntax-Reste durch <code>NoiseDetectionMetric</code> prüfen	<code>Score > 0.02</code>
5	<code>DocumentScore</code> mit allen Werten über Threshold erstellen	<code>passes_thresholds() = True</code>
6	<code>content_completeness = 0.50</code> setzen	<code>passes_thresholds() = False</code>

TC-US8-02: Regressionsprüfung Preprocessing-Qualität

Bezug: US8 – T037 · check_regression()

#	Schritt	Erwartetes Ergebnis
1	100 Dokumente simulieren, davon 15 mit <code>content_completeness < 0.85</code>	Testdaten bereit
2	<code>check_regression()</code> aufrufen	Ergebnis-Dict zurückgegeben
3	<code>check_regression()["content_completeness"]["pass"]</code> prüfen	<code>False</code> (< 90% bestehen)
4	Alle Dokumente über Threshold setzen und erneut prüfen	<code>True</code>

US9 – Architektur-Cleanup

TC-US9-01: Einzelner Einstiegspunkt

Bezug: US9 – T031 · run_preprocessing.py

#	Schritt	Erwartetes Ergebnis
1	Preprocessing-Modul-Verzeichnis auf <code>main.py</code> scannen	Datei existiert nicht
2	<code>run_preprocessing.py</code> auf Existenz prüfen	Existiert
3	<code>run_preprocessing.main()</code> auf Aufrufbarkeit prüfen	<code>callable(main) = True</code>
4	<code>run_preprocessing.run()</code> auf Aufrufbarkeit prüfen	<code>callable(run) = True</code>

Evaluierungsinfrastruktur

TC-MET-01: MRR-Berechnung (Forschungsfrage FF3)

Bezug: Constitution Art. III – Critical-Path Metrics

#	Schritt	Erwartetes Ergebnis
1	<code>reciprocal_rank(["a","b","c"], {"a"})</code> aufrufen	1.0
2	<code>reciprocal_rank(["a","b","c"], {"b"})</code> aufrufen	0.5
3	<code>reciprocal_rank(["a","b","c"], {"c"})</code> aufrufen	≈ 0.333
4	<code>mean_reciprocal_rank()</code> mit 3 Queries (RR: 1.0, 0.5, 1/3) aufrufen	≈ 0.6111
5	<code>mean_reciprocal_rank([])</code> aufrufen	0.0

TC-MET-02: NDCG@k-Berechnung

Bezug: Constitution Art. III – Critical-Path Metrics

#	Schritt	Erwartetes Ergebnis
1	Ideal-geordnete Relevanzliste übergeben	$\text{NDCG} = 1.0$
2	Händisch berechnetes Beispiel aus IR-Lehrbuch übergeben	≈ 0.972
3	Leere Relevanzmenge übergeben	0.0
4	Gleiche relevante Seite an Rang 1, 2 und 3 testen	$\text{NDCG}(\text{Rang1}) > \text{NDCG}(\text{Rang2}) > \text{NDCG}(\text{Rang3})$

TC-EVA-01: Modellvergleich-Pipeline E2E (gemockt)

Bezug: FF3 · `eval_model_comparison.py`

#	Schritt	Erwartetes Ergebnis
1	Corpus aus gemocktem <code>fetched_at_*</code> -Verzeichnis laden	Chunks geladen, Page-ID korrekt (Unterstrich → Doppelpunkt)
2	<code>run_model_evaluation()</code> mit gemocktem Qdrant und Embedding-Provider aufrufen	Läuft ohne Netzwerkzugriff durch
3	MRR im Ergebnis prüfen	MRR = 1.0 (Mock gibt richtiges Dokument zurück)
4	NFR-005-Felder im Ergebnis prüfen	<code>timestamp</code> , <code>config_hash</code> , <code>code_version</code> vorhanden
5	Fehlerfall simulieren (Qdrant schlägt fehl)	<code>delete_collection</code> wird trotzdem aufgerufen (Cleanup)

TC-EVA-02: Keyword-Baseline (Forschungsfrage FF1)

Bezug: FF1 · eval_keyword_baseline.py

#	Schritt	Erwartetes Ergebnis
1	<code>source_file="exams_matura-tagesschule-if-it.txt"</code> in Page-ID umwandeln	<code>exams:matura-tagesschule-if-it</code>
2	<code>source_file="archive_exams_semesterpruefungen.txt"</code> umwandeln	<code>archive:exams:semesterpruefungen</code>
3	<code>run_keyword_baseline()</code> mit Mock-API (gibt erwartete Seite zurück) aufrufen	MRR = 1.0, P@5 = 0.2
4	NFR-005-Felder im Ergebnis prüfen	<code>timestamp</code> , <code>config_hash</code> , <code>code_version</code> vorhanden

TC-RAG-01: RAGAS-Evaluator

Bezug: T029/T030/T031 · RAGASEvaluator

#	Schritt	Erwartetes Ergebnis
1	<code>RAGASEvaluator(llm_base_url, model)</code> mit gemocktem <code>ChatOpenAI</code> instanziiieren	Objekt erstellt, Attribute gesetzt
2	<code>ChatOpenAI</code> -Aufruf auf <code>temperature=0.0</code> prüfen	Temperature korrekt gesetzt
3	<code>evaluate([...])</code> mit gemocktem <code>_run_ragas_evaluate</code> aufrufen	Dict mit Metrik-Scores zurückgegeben
4	<code>evaluate([])</code> mit leerer Liste aufrufen	Leerer Dict zurückgegeben

Embeddings & Deployment

TC-EMB-01: Content-Aware Chunking

Bezug: pipeline/04_embeddings_creator · ContentAwareChunker

#	Schritt	Erwartetes Ergebnis
1	Dokument mit <code>content_type="EMPTY"</code> übergeben	Leere Chunk-Liste zurückgegeben
2	Dokument mit <code>content_type="KNOWLEDGE"</code> und 600 Zeichen bei <code>max_chunk_size=512</code> übergeben	Mehrere Chunks
3	Jeden Chunk auf Pflichtattribute prüfen	<code>chunk_id</code> , <code>text</code> , <code>chunk_index</code> , <code>total_chunks</code> vorhanden
4	<code>chunk_id</code> für ersten Chunk prüfen	Format: <code>"pages_my_page_0"</code>
5	Mix aus KNOWLEDGE- und EMPTY-Dokumenten durch <code>chunk_all()</code> laufen lassen	EMPTY übersprungen, KNOWLEDGE behalten

TC-EMB-02: Embedding-Ausgabeformat (MCP-Schema)

Bezug: pipeline/04_embeddings_creator · MCP Payload Schema

#	Schritt	Erwartetes Ergebnis
1	Embedding-Record aufbauen	Dict mit <code>id</code> , <code>text</code> , <code>embedding</code> , <code>metadata</code>
2	Embedding-Dimension prüfen	3072
3	Metadata auf MCP-Pflichtfelder prüfen	<code>text</code> , <code>source</code> , <code>collection</code> , <code>access_level</code> , <code>chunk_index</code> , <code>total_chunks</code>

TC-DEP-01: Direktupload zu Qdrant

Bezug: T082 · QdrantDeployer

#	Schritt	Erwartetes Ergebnis
1	JSONL-Datei mit 5 Vektorpunkten erstellen	Datei vorhanden
2	<code>QdrantDeployer.deploy_direct()</code> mit gemocktem Qdrant-Client aufrufen	Läuft durch
3	Rückgabewert prüfen	5 (Anzahl hochgeladener Punkte)
4	<code>deploy_direct()</code> mit leerer JSONL-Datei aufrufen	0

TC-DEP-02: Dry-Run-Modus

Bezug: T085 · QdrantDeployer – Validierung ohne Upload

#	Schritt	Erwartetes Ergebnis
1	<code>QdrantDeployer.deploy_direct(dry_run=True)</code> aufrufen	Läuft durch ohne Netzwerkzugriff
2	Anzahl valider Punkte im Rückgabewert prüfen	Korrekte Zahl zurückgegeben
3	Prüfen ob <code>upsert()</code> aufgerufen wurde	<code>upsert()</code> wurde nicht aufgerufen

2. Testprotokoll

Testlauf vom **2026-03-19** · Ausführungsumgebung: Windows 11, Python 3.13.7, pytest 8.4.2

TC-ID	Beschreibung	Ergebnis	Kommentar
TC-INF-01	Docker Compose Syntaxvalidität	bestanden	
TC-INF-02	Keine hartcodierten Secrets	bestanden	
TC-INF-03	Pflicht-Services vorhanden	bestanden	
TC-CFG-01	YAML-Konfiguration mit Placeholder-Auflösung	bestanden	
TC-CFG-02	Konfigurationshash (NFR-005)	bestanden	
TC-ORC-01	Pipeline-Stufenstruktur	bestanden	
TC-ORC-02	Gleichzeitige Jobs abweisen	bestanden	
TC-US1-01	CLI Hilfe-Banner	bestanden	
TC-US1-02	SIGINT-Signalbehandlung	bestanden	
TC-US2-01	Datei-Deduplizierung bei rglob	bestanden	
TC-US2-02	Temperature-Passthrough zum LLM	bestanden	
TC-US3-01	JSON-Schema-Validierung Pipeline Runs	bestanden	Zuvor fehlgeschlagen: preprocess fehlte im erwarteten Enum-Set – behoben
TC-US3-02	Frontmatter-Schema E2E-Roundtrip	bestanden	
TC-US4-01	Strategy Loader YAML	bestanden	Zuvor fehlgeschlagen: TABLE_DATA fehlte im erwarteten ContentType-Set – behoben
TC-US4-02	Content-Type-Routing	bestanden	
TC-US5-01	Freshness-Score-Berechnung	bestanden	
TC-US6-01	Bildunterschriftsgenerierung	bestanden	
TC-US7-01	PDF-Textbereinigung	bestanden	
TC-US8-01	7-Metrik-Qualitätssuite	bestanden	
TC-US8-02	Regressionsprüfung Preprocessing	bestanden	
TC-US9-01	Einzelner Einstiegspunkt	bestanden	
TC-MET-01	MRR-Berechnung	bestanden	
TC-MET-02	NDCG@k-Berechnung	bestanden	

TC-ID	Beschreibung	Ergebnis	Kommentar
TC-EVA-01	Modellvergleich-Pipeline E2E	bestanden	Zuvor fehlgeschlagen: <code>_expected_sources</code> ignorierte <code>.txt</code> -Extension – behoben
TC-EVA-02	Keyword-Baseline	bestanden	
TC-RAG-01	RAGAS-Evaluator	bestanden	Zuvor blockiert: <code>evaluation.ragas</code> -Paket fehlte – implementiert
TC-EMB-01	Content-Aware Chunking	bestanden	
TC-EMB-02	Embedding-Ausgabeformat	bestanden	
TC-DEP-01	Direktupload zu Qdrant	bestanden	
TC-DEP-02	Dry-Run-Modus	bestanden	

Ergebnis: 30 bestanden · 0 fehlgeschlagen · 0 blockiert

3. Testreport

Fortschritt des Projekts über die Testläufe auf Branch `009-analysis-and-production-polish`:

Datum	Bestanden	Fehlgeschlagen	Blockiert	Gesamt
2026-03-18	26	2	2	30
2026-03-19	30	0	0	30

Anmerkungen:

- **2026-03-18:** 2 Tests fehlgeschlagen (`TC-US3-01` fehlende Stage, `TC-US4-01` fehlender ContentType), 2 Tests blockiert (`TC-EVA-01` fehlende Funktion, `TC-RAG-01` fehlendes Paket)
- **2026-03-19:** Alle 4 Diskrepanzen behoben – alle 30 Testfälle bestanden

Automated Test Suite – Gesamtübersicht

Zusätzlich zu den 30 dokumentierten Testfällen werden **394 automatisierte Unit-Tests** durch pytest ausgeführt:

Suite	Bestanden	Fehlgeschlagen	Übersprungen	Gesamt
<code>tests/</code> – Root (Unit + Smoke)	55	0	0	55
<code>evaluation/tests/</code> – Evaluierungsinfrastruktur	125	0	2	127
<code>pipeline/02_deep_evaluation/tests/</code>	10	0	0	10
<code>pipeline/03_rag_preprocessing/tests/</code>	161	0	0	161
<code>pipeline/04_embeddings_creator/tests/</code>	19	0	0	19
<code>pipeline/05_deploy/tests/</code>	11	0	0	11
<code>pipeline/shared/tests/</code>	13	0	0	13
Gesamt	394	0	2	396

Die 2 übersprungenen Tests (`evaluation/tests/test_integration.py`) erfordern einen laufenden Qdrant-Service und werden in der lokalen Entwicklungsumgebung regulär übersprungen.

4. Rollen

Rolle	Person	Aufgaben
Test Author	Jan Riedler	Schreibt Testspezifikationen auf Basis der User Stories; implementiert automatisierte Unit-Tests
Tester	Jan Riedler	Führt Testläufe aus; dokumentiert Ergebnisse im Testprotokoll
Test Manager	Jan Riedler	Verantwortlich für den gesamten Testprozess; verfolgt Fortschritt im Testreport

Anhang A: Tests ausführen

Da die Pipeline-Module als eigenständige Skripte konzipiert sind (Constitution Art. VIII), teilen mehrere Module denselben Dateinamen (`config.py`, `pipeline.py`). Diese Suites werden daher separat ausgeführt:

```
# Root-Tests + Evaluierungsinfrastruktur
pytest tests/ evaluation/tests/

# Pipeline-Module einzeln
pytest pipeline/02_deep_evaluation/tests/
pytest pipeline/03_rag_preprocessing/tests/ pipeline/shared/tests/

# 04 und 05 aus ihrem eigenen Verzeichnis
cd pipeline/04_embeddings_creator && python -m pytest tests/
cd pipeline/05_deploy && python -m pytest tests/
```

Anhang B: Behobene Fehler

Beim ersten vollständigen Testlauf wurden vier Diskrepanzen zwischen Testerwartungen und Quellcode gefunden. In allen Fällen war der **Quellcode korrekt** – die Tests waren veraltet oder unvollständig.

B.1 Fehlende Pipeline-Stufe `preprocess` (TC-US3-01)

Datei: `tests/unit/test_pipeline_schemas.py`

Der Test erwartete `{fetch, evaluate, embed, deploy}` – das Schema definiert jedoch `{fetch, evaluate, preprocess, embed, deploy}`. **Behebung:** `preprocess` in das erwartete Set aufgenommen.

B.2 Fehlender Content-Type `TABLE_DATA` (TC-US4-01)

Datei: `pipeline/03_rag_preprocessing/tests/test_strategy_loader.py`

Der Test listete nur 6 von 7 Enum-Werten auf. `TABLE_DATA` war im Code korrekt definiert. **Behebung:** `TABLE_DATA` in das erwartete Set aufgenommen.

B.3 Fehlende Funktion `load_corpus_for_ground_truth` (TC-EVA-01)

Datei: `evaluation/tests/test_model_comparison.py` / `evaluation/scripts/eval_model_comparison.py`

Tests importierten eine nicht-existente Funktion. Außerdem Bug in `_expected_sources`: nur `.md`-Extensions wurden entfernt – `.txt`-Dateien aus dem Ground-Truth-Datensatz wurden dadurch nicht korrekt in Page-IDs umgewandelt.

Behebung: `_find_fetched_dir()` und `load_corpus_for_ground_truth()` implementiert; Extension-Stripping auf alle Endungen ausgeweitet.

```
# Vorher (nur .md erkannt):
stem = sf.rsplit(".", 1)[0] if sf.endswith(".md") else sf

# Nachher (alle Endungen entfernt):
stem = sf.rsplit(".", 1)[0] if "." in sf else sf
```

B.4 Fehlendes `evaluation/ragas/`-Paket (TC-RAG-01)

Datei: `evaluation/tests/test_ragas.py`

Tests importierten `RAGASEvaluator` aus einem nicht-existent Unterpaket. **Behebung:** `evaluation/ragas/__init__.py` und `evaluation/ragas/ragas_evaluator.py` implementiert.

Anhang C: Neue und geänderte Dateien

Neue Quelldateien

Datei	Beschreibung
<code>evaluation/ragas/__init__.py</code>	Paket-Init, re-exportiert <code>RAGASEvaluator</code>
<code>evaluation/ragas/ragas_evaluator.py</code>	RAGAS-Wrapper mit Ollama-kompatiblen LLM-Judge

Geänderte Quelldateien

Datei	Änderung
<code>evaluation/scripts/eval_model_comparison.py</code>	<code>_find_fetched_dir()</code> und <code>load_corpus_for_ground_truth()</code> hinzugefügt; <code>_expected_sources</code> Bugfix

Korrigierte Testdateien

Datei	Korrektur
<code>tests/unit/test_pipeline_schemas.py</code>	<code>preprocess</code> zur erwarteten Stage-Menge hinzugefügt
<code>pipeline/03_rag_preprocessing/tests/test_strategy_loader.py</code>	<code>TABLE_DATA</code> zur erwarteten ContentType-Menge hinzugefügt

Anhang D: Detaillierte Unit-Test-Spezifikationen

Alle 394 automatisierten Tests sind auf Funktionsebene mit SUT, Bedingung und erwartetem Ergebnis dokumentiert – gruppiert nach Datei und Klasse.

D.1 `tests/smoke/test_docker_compose.py`

Articles: III, VI

`TestDockerComposeSyntax`

Test	SUT	Bedingung	Erwartet
<code>test_compose_file_exists</code>	Datei-Existenz	Pfad geprüft	Vorhanden
<code>test_compose_is_valid_yaml</code>	YAML-Parsing	<code>docker-compose.yml</code> geladen	Enthält <code>services</code>
<code>test_compose_has_project_name</code>	Projektname	<code>name</code> -Feld	<code>"stack-g-devdito"</code>
<code>test_compose_has_networks</code>	Netzwerk	Networks geprüft	<code>leonidas-network</code> extern

`TestDockerfileReferences`

Test	SUT	Bedingung	Erwartet
<code>test_all_build_contexts_exist</code>	Build-Pfade	Services mit Build-Config	Alle Dockerfiles existieren

`TestNoHardcodedSecrets`

Test	SUT	Bedingung	Erwartet
<code>test_no_secrets_in_compose</code>	Secret-Scan compose	OpenAI-Keys, Tokens gesucht	Keine Treffer
<code>test_no_secrets_in_dockerfiles</code>	Secret-Scan Dockerfiles	Alle Dockerfiles	Keine Treffer

TestRequiredServices

Test	SUT	Bedingung	Erwartet
test_orchestrator_service_exists	Orchestrator	Services-Liste	Vorhanden
test_qdrant_service_exists	Qdrant	Services-Liste	Vorhanden
test_all_services_have_container_names	Container-Namen	Jede Service-Config	Alle haben container_name

D.2 tests/unit/test_config_loader.py

Articles: II-B, III

TestResolvePlaceholders

Test	SUT	Bedingung	Erwartet
test_simple_placeholder	\${root_dir}-Auflösung	Einfache Referenz	/test/root/config
test_nested_placeholder	Mehrstufige Auflösung	3 Ebenen	/test/root/config/secrets
test_no_placeholders	Pass-through	Ohne Placeholder	Werte unverändert
test_unresolvable_placeholder_preserved	Fehlende Variable	Undefinierter Placeholder	Bleibt erhalten
test_non_string_values_unchanged	Typ-Erhaltung	Numerisch/Boolean	Unverändert
test_list_values_resolved	Listen-Auflösung	Liste mit Placeholdern	Alle aufgelöst

TestLoadYamlConfig

Test	SUT	Bedingung	Erwartet
test_load_valid_yaml	YAML-Parsing	Gültige Datei	Dict mit APP.name
test_load_nonexistent_file_raises	Fehlende Datei	Pfad ungültig	FileNotFoundError
test_load_invalid_yaml_raises	Ungültiges YAML	Plain-String	ValueError

TestLoadSecretFile

Test	SUT	Bedingung	Erwartet
test_load_plain_token	Token-Extraktion	sk-test-token-12345	Token ohne Newlines
test_load_key_value_format	KEY=VALUE	TOKEN=my-secret-value	my-secret-value
test_missing_file_returns_empty	Fehlende Datei	Nicht vorhanden	""
test_jwt_token_not_split	JWT-Erhaltung	Token mit Punkten	Vollständig zurückgegeben

TestGetSetting

Test	SUT	Bedingung	Erwartet
test_get_existing_path	Verschachtelter Zugriff	APP.name	String-Wert
test_get_missing_path_returns_default	Default-Fallback	Fehlender Pfad	'fallback_value'
test_get_none_default	None-Default	Fehlend, kein Default	None

TestComputeConfigHash

Test	SUT	Bedingung	Erwartet
<code>test_same_config_same_hash</code>	Deterministik	Gleicher Dict 2×	Identisch
<code>test_different_config_different_hash</code>	Sensitivität	2 verschiedene Dicts	Verschieden
<code>test_meta_excluded_from_hash</code>	<code>_meta</code> -Ausschluss	Mit/ohne <code>_meta</code>	Identisch

TestPlaceholderEnvYaml

Test	SUT	Bedingung	Erwartet
<code>test_placeholder_yaml_is_valid</code>	Parsbarkeit	<code>PLACEHOLDER_env.yaml</code>	Gültig
<code>test_placeholder_has_required_sections</code>	Pflichtabschnitte	Dateinhalt	APP, PATHS, SERVICES, PIPELINE, PLUGIN

D.3 `tests/unit/test_orchestrator_stages.py`

TestPipelineStagesStructure

Test	SUT	Bedingung	Erwartet
<code>test_has_exactly_five_stages</code>	Stage-Anzahl	<code>PIPELINE_STAGES</code>	Genau 5
<code>test_each_stage_has_required_keys</code>	Stage-Schema	Jede Stage	<code>name</code> , <code>container</code> , <code>pipeline_dir</code>
<code>test_deploy_has_entrypoint_args</code>	Deploy-Einstiegspunkt	<code>deploy</code> -Stage	Hat <code>entrypoint_args</code>
<code>test_deploy_entrypoint_args_correct</code>	Deploy-Kommando	<code>entrypoint_args</code>	<code>["python", "run_deploy.py", "qdrant"]</code>
<code>test_embed_has_needs_openai_key</code>	OpenAI-Key	<code>embed</code> -Stage	<code>True</code>
<code>test_no_other_stage_needs_openai_key</code>	Key-Isolation	Alle anderen	<code>False</code>

TestGetLastRunSortKey

Test	SUT	Bedingung	Erwartet
<code>test_returns_none_when_no_runs</code>	Leere Datei	Keine Runs	<code>None</code>
<code>test_picks_latest_started_at_not_updated_at</code>	Sort-Kriterium	2 Runs, verschiedene Zeiten	Run mit späterem <code>started_at</code>

TestRunRequest / TestConcurrentJobRejection

Test	SUT	Bedingung	Erwartet
<code>test_default_options_is_empty_dict</code>	Default	Ohne <code>options</code>	<code>{}</code>
<code>test_options_accepts_string_dict</code>	Dict-Zuweisung	<code>{"mode": "incremental"}</code>	<code>options["mode"] = "incremental"</code>
<code>test_active_job_detected_when_status_running</code>	Aktiv-Erkennung	<code>status='running'</code>	Job zurückgegeben
<code>test_no_active_job_when_all_finished</code>	Leerlauf	Nur success/error	<code>None</code>

D.4 `tests/unit/test_pipeline_schemas.py`

Articles: II, III

TestPipelineRunsSchema

Test	SUT	Bedingung	Erwartet
<code>test_schema_file_exists</code>	Datei	Pfad	Existiert
<code>test_schema_is_valid_json</code>	JSON-Struktur	Geladen	Gültiger Dict
<code>test_schema_defines_array_type</code>	Root-Typ	Schema	<code>type = 'array'</code>
<code>test_schema_has_required_fields</code>	Pflichtfelder	<code>items.required</code>	<code>job_id</code> , <code>stage</code> , <code>status</code> , <code>started_at</code>
<code>test_schema_stage_enum</code>	Stage-Constraints	<code>stage</code> -Property	Alle 5 Stages
<code>test_schema_status_enum</code>	Status-Constraints	<code>status</code> -Property	<code>running</code> , <code>success</code> , <code>error</code> , <code>interrupted</code>

TestSchemaValidation / TestExistingPipelineRuns

Test	SUT	Bedingung	Erwartet
<code>test_valid_data_passes</code>	Validierung	Sample-Daten	Erfolgreich
<code>test_empty_array_passes</code>	Leere Daten	<code>[]</code>	Erfolgreich
<code>test_missing_required_field_fails</code>	Pflichtfeld	Ohne <code>job_id</code>	<code>ValidationError</code>
<code>test_invalid_stage_fails</code>	Enum	<code>stage='invalid_stage'</code>	<code>ValidationError</code>
<code>test_invalid_status_fails</code>	Enum	<code>status='unknown_status'</code>	<code>ValidationError</code>
<code>test_existing_runs_file_is_valid</code>	Echte Datei	Falls vorhanden	Valide

D.5 evaluation/tests/test_integration.py

Test	SUT	Bedingung	Erwartet
<code>test_qdrant_connection</code>	Qdrant-Verbindung	Service läuft	Collections-Liste (Übersprungen wenn nicht verfügbar)
<code>test_e2e_qdrant_embed_query_metrics</code>	E2E-Pipeline	Qdrant + Ollama	MRR > 0 (Übersprungen wenn nicht verfügbar)

D.6 evaluation/tests/test_keyword_baseline.py

TestSourceFileToPageId

Test	SUT	Bedingung	Erwartet
<code>test_single_namespace</code>	<code>_</code> → <code>:</code>	<code>exams_matura-tagesschule-if-it.txt</code>	<code>exams:matura-tagesschule-if-it</code>
<code>test_double_namespace</code>	Mehrfach	<code>archive_exams_semesterpruefungen.txt</code>	<code>archive:exams:semesterpruefungen</code>
<code>test_triple_namespace</code>	Drei Ebenen	<code>it_studentmail2023_android_gmail.txt</code>	<code>it:studentmail2023:android:gmail</code>
<code>test_no_namespace</code>	Ohne <code>_</code>	<code>start.txt</code>	<code>start</code>
<code>test_hyphens_preserved</code>	Bindestriche	<code>exams_da-inf-it.txt</code>	<code>exams:da-inf-it</code>
<code>test_all_ground_truth_sources</code>	Batch	Mehrere Beispiele	Alle gültig, kein <code>.txt</code> -Suffix

TestRunKeywordBaseline

Test	SUT	Bedingung	Erwartet
<code>test_perfect_hits</code>	Pipeline	Mock gibt richtigen Rang	MRR=1.0, P@5=0.2
<code>test_no_hits</code>	Kein Treffer	Mock irrelevant	MRR=0.0
<code>test_result_has_nfr005_fields</code>	NFR-005	Evaluation fertig	<code>timestamp</code> , <code>config_hash</code> , <code>code_version</code>

D.7 `evaluation/tests/test_metrics.py`

Article: III

TestReciprocalRank

Test	SUT	Bedingung	Erwartet
<code>test_relevant_at_rank_1</code>	RR	<code>relevant={"a"}</code>	1.0
<code>test_relevant_at_rank_2</code>	RR	<code>relevant={"b"}</code>	0.5
<code>test_relevant_at_rank_3</code>	RR	<code>relevant={"c"}</code>	≈1/3
<code>test_no_relevant_results</code>	RR	<code>relevant={"x"}</code>	0.0
<code>test_empty_results</code>	RR	<code>ranked=[]</code>	0.0
<code>test_empty_relevant_set</code>	RR	<code>relevant={}</code>	0.0
<code>test_multiple_relevant_returns_first</code>	Erster Treffer	<code>relevant={"b","c"}</code>	0.5

TestMeanReciprocalRank

Test	SUT	Bedingung	Erwartet
<code>test_basic_mrr</code>	MRR	3 Queries	≈0.6111
<code>test_empty_queries</code>	Leer	<code>[]</code>	0.0
<code>test_all_miss</code>	Alle Misses	Keine Treffer	0.0
<code>test_perfect_mrr</code>	Perfekt	Alle Rang 1	1.0

TestPrecisionAtK

Test	SUT	Bedingung	Erwartet
<code>test_all_relevant</code>	P@k	Alle relevant	1.0
<code>test_none_relevant</code>	P@k	Keine Treffer	0.0
<code>test_partial_relevant</code>	P@k	2/5 relevant	0.4
<code>test_k_larger_than_results</code>	P@k	k=5, 2 Ergebnisse	0.2
<code>test_k_zero</code>	P@k	k=0	0.0
<code>test_empty_results</code>	P@k	Leer	0.0
<code>test_p_at_5</code>	P@5	3 relevant in 7	0.6

TestMeanPrecisionAtK / TestNdcgAtK / TestMeanNdcgAtK

Test	SUT	Bedingung	Erwartet
<code>test_basic</code> (MeanP@k)	Aggregation	2 Queries	0.75
<code>test_perfect_ranking</code> (NDCG)	Ideal	Optimal geordnet	1.0
<code>test_reverse_ranking</code> (NDCG)	Worst-Case	Umgekehrt	$0 < x < 1$
<code>test_no_relevant_documents</code> (NDCG)	Leer	Keine Relevanz	0.0
<code>test_hand_calculated_example</code> (NDCG)	Lehrbuch	Spezifische Konfig	≈ 0.972
<code>test_single_relevant_at_various_positions</code> (NDCG)	Sensitivität	Rang 1/2/3	Rang1 > Rang2 > Rang3

D.8 evaluation/tests/test_model_comparison.py

Test	SUT	Bedingung	Erwartet
<code>test_empty_text</code>	Chunk	<code>""</code>	<code>[]</code>
<code>test_short_text_single_chunk</code>	Chunk	Unter Limit	1 Chunk
<code>test_respects_chunk_size</code>	Chunk	600 Zeichen, size=250	Mehrere ≤ 300
<code>test_high_overlap</code>	Relevanz	Ähnliche Texte	> 0.3
<code>test_no_overlap</code>	Relevanz	Unverwandt	< 0.2
<code>test_keyword_boost</code>	Keyword-Gewichtung	Mit/ohne Keywords	Mit > ohne
<code>test_loads_from_fetched_dir</code>	Corpus-Laden	Mock-Verzeichnis	Chunks mit Page-ID
<code>test_full_pipeline_mocked</code>	E2E	Alles gemockt	MRR=1.0, NFR-005
<code>test_cleanup_on_error</code>	Cleanup	Fehler in Suche	<code>delete_collection</code> aufgerufen

D.9 evaluation/tests/test_new_metrics.py

Test	SUT	Bedingung	Erwartet
<code>test_all_relevant_in_top_k</code>	Recall@k	Alle gefunden	1.0
<code>test_some_relevant_in_top_k</code>	Recall@k	2/3 gefunden	2/3
<code>test_none_relevant_in_top_k</code>	Recall@k	Kein Treffer	0.0
<code>test_k_larger_than_results</code>	Recall@k	$k > \text{Ergebnisse}$	1.0
<code>test_basic_mean_recall</code>	MeanRecall	3 Queries	2/3
<code>test_perfect_ranking</code> (AP)	AP	Ideal	1.0
<code>test_one_relevant_at_rank_2</code> (AP)	AP	Ein Treffer Rang 2	0.5
<code>test_basic_map</code>	MAP	2 Queries	0.75
<code>test_hit_when_relevant_in_top_k</code>	Hit@k	Treffer	1
<code>test_miss_when_no_relevant_in_top_k</code>	Hit@k	Kein Treffer	0
<code>test_all_hits</code>	Hit-Rate	Alle Queries	1.0
<code>test_half_hits</code>	Hit-Rate	Hälfte	0.5

D.10 evaluation/tests/test_providers.py

Article: III

Test	SUT	Bedingung	Erwartet
test_cannot_instantiate_abc	ABC	Direkte Instanz	<code>TypeError</code>
test_properties (Ollama)	Attribute	Init	Korrekt gesetzt
test_is_embedding_provider (Ollama)	Interface	Instanz	<code>isinstance = True</code>
test_embed_calls_sdk (Ollama)	SDK-Aufruf	Gemockt	<code>embed()</code> aufgerufen
test_properties (OpenAI)	Attribute	Init	<code>cost_per_token</code> gesetzt
test_is_embedding_provider (OpenAI)	Interface	Instanz	<code>isinstance = True</code>
test_embed_tracks_tokens (OpenAI)	Token-Tracking	Gemockte Response	<code>total_tokens</code> inkrementiert

D.11 evaluation/tests/test_ragas.py

Task IDs: T029-T031

Test	SUT	Bedingung	Erwartet
test_init_accepts_llm_base_url_and_model	Konstruktor	Init	Attribute gesetzt
test_init_default_temperature_zero	Temperature	Kein Wert	<code>ChatOpenAI(temperature=0.0)</code>
test_init_calls_chat_openai_with_base_url	Base-URL	Konstruktor	<code>base_url</code> und <code>model</code> übergeben
test_evaluate_returns_dict_of_metric_scores	Evaluate	Mock	Dict mit Scores
test_evaluate_empty_data_returns_empty_or_sensible	Leer	<code>[]</code>	Dict
test_evaluate_logs_and_continues_on_single_item_failure	Fehlerfall	Exception	Propagiert
test_evaluate_handles_ragas_import_error_gracefully	Import-Fehler	RAGAS fehlt	Leerer Dict

D.12 evaluation/tests/test_reports.py

Task IDs: T051-T054

Test	SUT	Bedingung	Erwartet
test_generate_returns_markdown_and_json_paths	Generierung	JSON-Dateien	<code>(md_path, json_path)</code>
test_markdown_contains_required_sections	Inhalt	Markdown	<code># Evaluation Report</code> , <code>## Executive Summary</code>
test_json_is_valid_and_has_sections	Struktur	JSON	<code>executive_summary</code> , <code>custom_metrics</code>
test_custom_metrics_table_in_markdown	Metriktable	Markdown	<code>MRR</code> enthalten
test_ragas_section_in_markdown	RAGAS	Scores vorhanden	<code>RAGAS</code> enthalten
test_json_contains_timestamp	NFR-005	JSON	<code>timestamp</code>
test_json_contains_config_hash	NFR-005	JSON	<code>config_hashes</code>
test_json_contains_code_version	NFR-005	JSON	<code>code_version</code>
test_difficulty_breakdown_in_markdown	Schwierigkeit	Markdown	<code>Difficulty</code>
test_difficulty_breakdown_in_json	Schwierigkeit	JSON	<code>difficulty_breakdown</code> -Dict

D.13 evaluation/tests/test_statistics.py

Test	SUT	Bedingung	Erwartet
<code>test_returns_bootstrap_ci_dataclass</code>	Bootstrap-CI	20 Samples	<code>BootstrapCI</code> mit mean, ci_lower, ci_upper
<code>test_small_sample</code>	Klein	<code>[0.5,0.6,0.7]</code>	mean=0.6, ci_lower<ci_upper
<code>test_empty_scores_raises_or_returns_sensible</code>	Leer	<code>[]</code>	Exception
<code>test_returns_comparison_result</code>	Paired-Test	2 Listen	<code>ComparisonResult</code>
<code>test_identical_lists</code>	Kein Unterschied	Gleich	diff=0, effect=0
<code>test_different_length_raises</code>	Mismatch	Verschiedene Längen	<code>ValueError</code>
<code>test_returns_float_and_interpretation</code>	Cohen's d	2 Gruppen	<code>(float, str)</code>
<code>test_identical_lists_zero_effect</code>	Kein Effekt	Gleich	d=0.0
<code>test_returns_dict_with_mean_median_std</code>	Deskriptiv	5 Werte	mean, median, std
<code>test_returns_list_of_comparison_results</code>	Konfig-Vergleich	JSON-Dateien	Liste von Ergebnissen
<code>test_missing_file_raises</code>	Fehlend	Ungültige Pfade	<code>FileNotFoundError</code>

D.14 evaluation/tests/test_visualization.py

Task IDs: T038-T042

Test	SUT	Bedingung	Erwartet
<code>test_radar_chart_returns_path</code>	Radar	Multi-Modell	PNG-Pfad
<code>test_radar_chart_file_not_empty</code>	Inhalt	PNG	Größe > 0
<code>test_radar_chart_creates_output_dir</code>	Verzeichnis	Fehlend	Auto-erstellt
<code>test_box_plot_returns_path</code>	Box-Plot	Scores	PNG-Pfad
<code>test_box_plot_file_not_empty</code>	Inhalt	PNG	Größe > 0
<code>test_bar_comparison_returns_path</code>	Balken	Multi-Modell	PNG-Pfad
<code>test_heatmap_returns_path</code>	Heatmap	Matrix	PNG-Pfad
<code>test_svg_radar_chart</code>	SVG	<code>fmt="svg"</code>	SVG-Datei
<code>test_svg_bar_comparison</code>	SVG	<code>fmt="svg"</code>	SVG-Datei
<code>test_svg_box_plot</code>	SVG	<code>fmt="svg"</code>	SVG-Datei
<code>test_svg_heatmap</code>	SVG	<code>fmt="svg"</code>	SVG-Datei

D.15 pipeline/02_deep_evaluation/tests/test_deep_eval_bugfixes.py

Task IDs: T049-T052b

Test	SUT	Bedingung	Erwartet
<code>test_analyze_documents_no_duplicates</code>	Datei-Dedup	<code>.pdf</code> + <code>.PDF</code>	Nur einmal
<code>test_analyze_images_no_duplicates</code>	Bild-Dedup	<code>.jpg</code> + <code>.JPG</code>	Nur einmal
<code>test_env_yaml_has_temperature_zero</code>	Config	<code>env.yaml</code>	<code>0.0</code>
<code>test_llm_client_passes_temperature</code>	LLM	Client-Init	<code>gen_params["temperature"]==0.0</code>
<code>test_wiki_strategies_no_duplicate_ids</code>	YAML-Dedup	Doppelte Page-IDs	Eindeutig
<code>test_document_strategies_no_duplicate_files</code>	YAML-Dedup	Doppelte Dateien	Eindeutig
<code>test_media_strategies_no_duplicate_files</code>	YAML-Dedup	Doppelte Media	Eindeutig
<code>test_ignored_wiki_strategies_no_duplicate_ids</code>	YAML-Dedup	Ignored-Liste	Eindeutig
<code>test_structural_override_table_data</code>	Heuristik	60% Tabellenzeilen	Override → <code>TABLE_DATA</code>
<code>test_summary_is_single_log_call</code>	Logging	<code>main()</code>	Ein <code>logger.info()</code> -Aufruf

D.16 `pipeline/03_rag_preprocessing/tests/test_architecture_cleanup.py`

Task ID: T031

Test	SUT	Bedingung	Erwartet
<code>test_main_py_does_not_exist</code>	Konsolidierung	Verzeichnis-Scan	<code>main.py</code> nicht vorhanden
<code>test_run_preprocessing_exists</code>	Einstiegspunkt	Verzeichnis	<code>run_preprocessing.py</code> vorhanden
<code>test_run_preprocessing_has_main</code>	Funktion	Import	<code>callable(main)</code>
<code>test_run_preprocessing_has_run</code>	Funktion	Import	<code>callable(run)</code>
<code>test_run_preprocessing_help</code>	<code>--help</code>	Aufruf	<code>SystemExit(0)</code>
<code>test_document_extensions_constant</code>	Konstante	<code>DOCUMENT_EXTENSIONS</code>	<code>.pdf</code> , <code>.docx</code> , <code>.xlsx</code> , <code>.pptx</code>
<code>test_image_extensions_constant</code>	Konstante	<code>IMAGE_EXTENSIONS</code>	<code>.png</code> , <code>.jpg</code> , <code>.jpeg</code>
<code>test_process_docx_method_exists</code>	Methode	Klasse	<code>callable(process_docx)</code>
<code>test_process_xlsx_method_exists</code>	Methode	Klasse	<code>callable(process_xlsx)</code>
<code>test_process_pptx_method_exists</code>	Methode	Klasse	<code>callable(process_pptx)</code>
<code>test_process_media_directory_handles_all_formats</code>	Abdeckung	Alle Formate	Liste zurückgegeben
<code>test_process_docx_nonexistent_file</code>	Fehlend	Ungültig	<code>""</code>
<code>test_process_xlsx_nonexistent_file</code>	Fehlend	Ungültig	<code>""</code>
<code>test_process_pptx_nonexistent_file</code>	Fehlend	Ungültig	<code>""</code>

D.17 `pipeline/03_rag_preprocessing/tests/test_eval_metrics.py`

Task ID: T037

Test	SUT	Bedingung	Erwartet
<code>test_identical_text_returns_1</code>	Completeness	Gleich	≈ 1.0
<code>test_half_content_returns_low</code>	Completeness	80/200 Zeichen	< 0.85
<code>test_markup_removed_still_passes</code>	Completeness	Wiki→MD	≥ 0.70
<code>test_identical_texts_high_score</code>	Semantic	Gleich	≥ 0.95
<code>test_different_texts_lower_score</code>	Semantic	Unverwandt	< 0.85
<code>test_all_entities_preserved</code>	Entity	Datum, Raum, Mail, URL	1.0
<code>test_entity_lost_reduces_score</code>	Entity	E-Mail weg	$0.5 \leq x < 1.0$
<code>test_links_preserved</code>	Link	<code>[[]]</code> → <code>[]()</code>	≥ 0.90
<code>test_clean_text_low_noise</code>	Noise	Sauber	≤ 0.02
<code>test_wiki_syntax_detected</code>	Noise	Wiki-Reste	> 0.02
<code>test_simple_text_readable</code>	Readability	Deutsch einfach	≥ 20
<code>test_threshold_is_20_not_60</code>	Threshold	Deutsch	≈ 20.0
<code>test_structure_fully_preserved</code>	Structure	Wiki→MD	≥ 0.80
<code>test_passes_thresholds</code>	DocScore	Alle über Threshold	<code>True</code>
<code>test_fails_thresholds_low_completeness</code>	DocScore	completeness=0.50	<code>False</code>
<code>test_regression_fails_below_90_percent</code>	Regression	15% scheitern	<code>False</code>
<code>test_regression_passes_above_90_percent</code>	Regression	Alle bestehen	<code>True</code>

D.18 `pipeline/03_rag_preprocessing/tests/test_exporter.py`

Task IDs: T066, T006

Test	SUT	Bedingung	Erwartet
<code>test_export_returns_path</code>	Export	Sample-Seiten	Existierender Pfad
<code>test_export_creates_timestamped_dir</code>	Verzeichnis	Export	Beginnt mit <code>"preprocessed_at_"</code>
<code>test_export_creates_pages_subdir</code>	Struktur	Seiten	<code>pages/</code> mit <code>.md</code> -Dateien
<code>test_export_creates_media_subdir</code>	Struktur	Media	<code>media/</code> mit <code>.md</code> -Dateien
<code>test_media_output_has_md_extension_not_txt</code>	Endung	Media	<code>.md</code> , kein <code>.txt</code>
<code>test_exported_file_has_yaml_frontmatter</code>	Frontmatter	Datei	<code>—\n</code> ... <code>—\n</code>
<code>test_export_empty_pages_returns_dir</code>	Leer	Keine Seiten	Verzeichnis erstellt
<code>test_page_has_all_required_fields</code>	Pflichtfelder	Seite	14 Felder
<code>test_content_hash_is_md5_of_body</code>	Hash	Seite	MD5(body), 32 Zeichen
<code>test_freshness_score_is_float</code>	Typ	Frontmatter	Float
<code>test_links_to_is_list</code>	Typ	Frontmatter	Liste
<code>test_linked_from_is_list</code>	Typ	Frontmatter	Liste
<code>test_media_uses_media_id</code>	Media-ID	Media	<code>media_id</code> , kein <code>page_id</code>
<code>test_media_has_all_required_fields</code>	Media	Felder	Alle vorhanden

D.19 pipeline/03_rag_preprocessing/tests/test_image_captioner.py

Task ID: T026

Test	SUT	Bedingung	Erwartet
test_caption_returns_description_string	Caption	Gültiges PNG	Deutschen String
test_caption_graceful_failure_returns_empty	Fehler	API-Fehler	" "
test_caption_nonexistent_file_returns_empty	Fehlend	Kein Pfad	" "
test_is_available_returns_false_when_unreachable	Verfügbarkeit	Ungültiger Endpunkt	False
test_is_available_returns_true_when_reachable	Verfügbarkeit	Gemockt	True
test_encodes_image_to_base64	Base64	PNG	"data:image/png;base64, ... "
test_png_jpg_supported	Konstante	CAPTIONABLE_EXTENSIONS	.png , .jpg , .jpeg
test_pdf_not_captionable	Konstante	CAPTIONABLE_EXTENSIONS	Kein .pdf

D.20 pipeline/03_rag_preprocessing/tests/test_media_processor.py

Task IDs: T065, T021

Test	SUT	Bedingung	Erwartet
test_process_pdf_returns_string	PDF	Gemockt	String
test_process_pdf_tries_docling_first	Docling-Priorität	Docling liefert MD	Docling-Output
test_process_pdf_fallback_to_ocr	OCR-Fallback	Docling+pypdf leer	OCR-Ergebnis
test_process_pdf_missing_file	Fehlend	Kein PDF	" "
test_process_docx_tries_docling_first	Docling	DOCX	Markdown
test_process_docx_fallbackextracts_tables	Tabellen	Docling leer	`
test_process_xlsx_tries_docling_first	Docling	XLSX	Markdown
test_process_xlsx_fallbackproduces_markdown_tables	Tabellen	Docling leer	`
test_process_image_returns_string	OCR	Gemockt	String
test_process_image_missing_file	Fehlend	Kein Bild	" "
test_directory_returns_list	Verzeichnis	Media-Dir	Liste
test_directory_entries_have_required_keys	Struktur	Verarbeitet	filename , text , type
test_htbla_leonding	Spaced-Chars	"H T B L A ... "	"HTBLA Leonding"
test_normal_text_unchanged	No-op	Normal	Unverändert
test_joins_consecutive_short_lines	Zeilen-Merge	Kurze Zeilen	Zusammengeführt
test_respects_sentence_boundaries	Satzenden	.-Zeilen	Grenzen respektiert
test_preserves_list_items	Listen	Bullet-Items	Getrennt
test_preserves_headings	Überschriften	#-Zeilen	Getrennt
test_chains_spaced_chars_then_merge	Pipeline	Beide Fälle	Beide angewendet
test_process_pdf_integrates_clean	Integration	Raw PDF	Bereinigt

D.21 pipeline/03_rag_preprocessing/tests/test_metadata_enricher.py

Task IDs: T068, T007, T017, T077, T078

Test	SUT	Bedingung	Erwartet
test_26_day_old_returns_fresh_1_0	Freshness	26 Tage	score=1.0, fresh
test_60_day_old_returns_fresh_1_0	Freshness	60 Tage	score=1.0, fresh
test_120_day_old_returns_fresh_0_85	Freshness	120 Tage	score=0.85, fresh
test_300_day_old_returns_fresh_0_85	Freshness	300 Tage	score=0.85, fresh
test_650_day_old_returns_recent_0_70	Freshness	650 Tage	score=0.70, recent
test_800_day_old_returns_outdated_0_50	Freshness	800 Tage	score=0.50, outdated
test_1500_day_old_returns_stale_0_30	Freshness	1500 Tage	score=0.30, stale
test_archive_namespace_always_archived	Freshness	archive: ...	score=0.20, archived
test_invalid_date_returns_default	Fehler	Ungültig	score=0.5, unknown
test_teacher_namespace	Access	teacher:docs	teacher_only
test_lehrer_namespace	Access	lehrer:material	teacher_only
test_public_namespace	Access	departm: ...	public
test_empty_namespace	Access	""	public
test_field_name_is_last_modified_not_modified_at	Feldname	Frontmatter	last_modified (kein modified_at)
test_linked_from_populated_from_backlinks	Backlinks	Übergeben	linked_from befüllt
test_source_url_uses_wiki_base_url	Source-URL	base+page_id	Korrekt kombiniert

D.22 pipeline/03_rag_preprocessing/tests/test_page_processor.py

Task IDs: T067, T076

Test	SUT	Bedingung	Erwartet
test_heading_h1	H1	"==== Title ====="	"# Title"
test_heading_h2	H2	"==== Sub ====="	"## Sub"
test_bold_text	Fett	"**bold**"	"**bold**"
test_italic_text	Kursiv	"//italic//"	"*italic*"
test_internal_link	Link	`"[[page	text]]"`
test_internal_link_namespace_colon_lowercase	Namespace	`"[[departm:ELD	...]]"`
test_unordered_list	Liste	" * item"	"- item"
test_table_conversion	Tabelle	"^ H1 ^ H2 ^"	`"
test_empty_content_fails	Leer	""	result.success = False
test_knowledge_page	Routing	KNOWLEDGE	content_type="knowledge"
test_news_page	Routing	NEWS	content_type="news"
test_archived_page_marked_low_priority	Routing	ARCHIVED	priority="low"

D.23 pipeline/03_rag_preprocessing/tests/test_regression_wiki_syntax.py

Task ID: T081

Test	SUT	Bedingung	Erwartet
<code>test_conversion_removes_almost_all_wiki_syntax</code>	Syntax-Entfernung	Komplex	<1% Wiki-Muster
<code>test_headings_fully_converted</code>	Überschriften	Alle Ebenen	Kein <code>"===="</code> mehr
<code>test_links_fully_converted</code>	Links	<code>[[[]]]</code> -Muster	Kein <code>[[</code> oder <code>]]</code>
<code>test_media_fully_converted</code>	Media	<code>{{{}}}</code> -Muster	Kein <code>{{</code> oder <code>}}</code>

D.24 `pipeline/03_rag_preprocessing/tests/test_run_preprocessing.py`

Test	SUT	Bedingung	Erwartet
<code>test_backlinks_use_page_id_from_json</code>	Backlinks-Key	JSON mit <code>page_id</code>	Keys aus JSON
<code>test_backlinks_fallback_stem_when_no_page_id</code>	Fallback	Kein <code>page_id</code>	Stem-Transformation
<code>test_backlinks_empty_dir</code>	Fehlend	Kein Verzeichnis	<code>{}</code>

D.25 `pipeline/03_rag_preprocessing/tests/test_schema_e2e.py`

Task ID: T005

Test	SUT	Bedingung	Erwartet
<code>test_page_roundtrip_all_fields_present</code>	Roundtrip	Seite exportiert+geladen	14 Felder
<code>test_media_roundtrip_uses_media_id</code>	Media	Exportiert+geladen	<code>media_id</code> , kein <code>page_id</code>
<code>test_content_hash_is_md5_of_body_without_frontmatter</code>	Hash	Exportiert	MD5(body only)
<code>test_output_has_pages_and_media_subdirs</code>	Struktur	Export	<code>pages/</code> und <code>media/</code>
<code>test_manifest_json_created</code>	Manifest	Export	<code>manifest.json</code> mit Zählern

D.26 `pipeline/03_rag_preprocessing/tests/test_strategy_loader.py`

Task IDs: T064, T013

Test	SUT	Bedingung	Erwartet
<code>test_load_yaml_finds_file</code>	YAML-Laden	Datei vorhanden	Strategien geladen
<code>test_knowledge_articles_mapping</code>	Mapping	knowledge_articles	KNOWLEDGE + recursive_header
<code>test_portals_mapping</code>	Mapping	portals	PORTAL + parent_context
<code>test_news_mapping</code>	Mapping	news	NEWS + naive
<code>test_forms_wiki_page_mapping</code>	Mapping	forms	FORM
<code>test_ignored_pages_skipped</code>	Ignored	In Liste	<code>is_ignored()</code> =True
<code>test_underscore_to_colon_conversion</code>	Konvertierung	YAML mit <code>_</code>	Abfrage mit <code>:</code>
<code>test_unknown_page_gets_default</code>	Default	Unbekannt	KNOWLEDGE, semantic, process
<code>test_informative_images_action</code>	Media	Informativ	<code>caption_and_index</code>
<code>test_decorative_images_skip</code>	Media	Dekorativ	<code>skip</code>
<code>test_document_strategy</code>	Media	PDF-Dokument	Hat <code>parser</code>
<code>test_thesis_document</code>	Media	Wissenschaftlich	<code>pdf_scientific</code>
<code>test_unknown_media_gets_default</code>	Media	Unbekannt	<code>process</code> , <code>DOCUMENT</code>
<code>test_json_fallback</code>	JSON	<code>page_strategies.json</code>	Geladen
<code>test_yaml_preferred_over_json</code>	Präferenz	Beide vorhanden	YAML gewinnt
<code>test_empty_dir_no_error</code>	Leer	Kein File	Defaults
<code>test_all_types_exist</code>	Enum	ContentType	Alle 7 Typen

D.27 `pipeline/04_embeddings_creator/tests/test_content_aware_chunker.py`

Test	SUT	Bedingung	Erwartet
<code>test_chunk_has_required_attributes</code>	Felder	Chunk erstellt	<code>chunk_id</code> , <code>text</code> , <code>chunk_index</code> , <code>total_chunks</code> , <code>source</code> , <code>collection</code> , <code>access_level</code>
<code>test_chunk_id_format</code>	Format	Erster Chunk	<code>"pages_my_page_0"</code>
<code>test_chunk_index_and_total_chunks</code>	Tracking	Mehrere Chunks	Korrekte Werte
<code>test_skip_empty_content_type</code>	Skip	EMPTY	<code>[]</code>
<code>test_do_not_skip_knowledge</code>	Verarbeiten	KNOWLEDGE	≥1 Chunk
<code>test_short_text_single_chunk</code>	Semantisch	Kurz	1 Chunk
<code>test_respects_max_chunk_size</code>	Größe	600 Zeichen, max 512	Mehrere Chunks
<code>test_naive_splits_long_text</code>	Naiv	NEWS, 1500 Zeichen	Mehrere Chunks
<code>test_prepare_text_adds_frontmatter_when_configured</code>	Frontmatter	<code>include=True</code>	Titel+Body
<code>test_returns_content_type_config</code>	Config	KNOWLEDGE	<code>method="recursive_header"</code>
<code>test_chunk_all_returns_flat_list</code>	Multi-Doc	2 Dokumente	Flache Liste
<code>test_chunk_all_skips_empty_type</code>	Filter	Mix KNOWLEDGE+EMPTY	EMPTY übersprungen

D.28 pipeline/04_embeddings_creator/tests/test_embedding_output_format.py

Test	SUT	Bedingung	Erwartet
test_record_has_required_top_level_keys	Struktur	Record gebaut	id , text , embedding , metadata
test_record_id_is_string	Typ	ID	String
test_embedding_dimensions_3072	Dimension	Konstante	3072
test_build_metadata_contains_mcp_payload_fields	Metadata	MCP-Felder	text , source , collection , access_level , chunk_index , total_chunks

D.29 pipeline/05_deploy/tests/test_deploy_qdrant.py

Task IDs: T082-T085

Test	SUT	Bedingung	Erwartet
test_deploy_direct_returns_count	Upload	5 Punkte	5
test_deploy_direct_calls_upsert	Methode	Direct	upsert() aufgerufen
test_deploy_direct_creates_collection_if_missing	Erstellung	Fehlt	create_collection()
test_deploy_direct_empty_file	Leer	Leeres JSONL	0
test_deploy_watchdog_returns_path	Watchdog	Copy-Mode	Existierender Pfad
test_deploy_watchdog_copies_file	Kopieren	Quelldatei	Identischer Inhalt
test_deploy_watchdog_creates_output_dir	Verzeichnis	Fehlt	Erstellt
test_recreate_deletes_existing_collection	Recreate	recreate=True	delete_collection aufgerufen
test_recreate_false_keeps_collection	Kein Recreate	recreate=False	delete_collection NICHT aufgerufen
test_upsert_adds_to_existing_collection	Upsert-Only	recreate=False	Punkte hinzugefügt
test_dry_run_does_not_upload	Dry-Run	dry_run=True	upsert NICHT aufgerufen

D.30 pipeline/shared/tests/test_cli_utils.py

Task ID: T054

Test	SUT	Bedingung	Erwartet
<code>test_returns_ansi_when_color_enabled</code>	ANSI	Farbe an, "green"	<code>\033[32m</code> und <code>\033[0m</code>
<code>test_returns_plain_when_color_disabled</code>	Plain	Farbe aus	Kein Escape-Code
<code>test_multiple_codes</code>	Mehrere Codes	"bold"+"yellow"	<code>\033[1m</code> und <code>\033[33m</code>
<code>test_no_codes_returns_plain</code>	Kein Styling	Kein Code	Klartext
<code>test_unknown_code_ignored</code>	Unbekannt	Unbekannter Code	Ignoriert
<code>test_handler_exits_130</code>	SIGINT	Signal	<code>SystemExit(130)</code>
<code>test_handler_calls_callback</code>	Callback	Mit Callback	Einmal aufgerufen
<code>test_handler_prints_abort_banner</code>	Banner	Ausgeführt	<code>"ABGEBROCHEN"</code> in <code>stderr</code>
<code>test_all_sections_present</code>	Hilfe	Alle Parameter	8 Abschnitte
<code>test_empty_sections_omitted</code>	Optional	Nur <code>what</code>	Nur <code>what</code> angezeigt
<code>test_runs_without_error</code>	Windows-ANSI	Aufruf	Keine Exception
<code>test_add_no_color_arg</code>	CLI-Arg	Parser-Setup	<code>--no-color</code> akzeptiert
<code>test_apply_disables_color</code>	Deaktivierung	<code>--no-color</code>	<code>get_use_color()=False</code>